

AI Prediction & Ecosystem White Paper ^{JP}

AIPE COIN: TABLE OF CONTENTS

Abstract	01
Services	02
3PIKS	02
AIBitBip	02
AI Auto-Trading	02
AI Prediction Platform	03
Exchange Solution	03
AI Prediction Ecosystem	04
AI技術	05
概要	05
主要技術紹介	06
TOKEN Economy	14
Coin Structure	14
Allocation	14
Ecosystem	15
Road Map	15
Notice & Caution	16

ABSTRACT

「人工知能（Artificial Intelligence、以下AI）」は、イ・セドル九段とアルファ碁（AlphaGo）の対局で世の中に広く知られると同時に大きな反響を呼んだ。その後、世界的に様々な分野で使われるようになった。金融と関連したサービスおよび保険(BFSI)分野をはじめ、生命科学や教育分野で活発に利用されており、政府、国防、製造、エネルギー、輸送、医療を含む各種の産業での利用だけでなく、小売、通信、メディア、エンターテインメント、スポーツに至る生活部分にまで広く利用されている。

実際、知能型ビジネスプロセスに対する要求が増えつつあり使用者に伝わる全般的な経験が向上している。これに合わせてGoogle、Microsoft、IBM、AWS、Intel、FICO（Fair Isaac Corporation）、Salesforce、Baidu、SASなどのグローバル企業は、AI機能を既存のビジネス応用プログラムと統合することに注力している。

グローバル市場調査機関のResearch and Marketsの発表によると、AIサービス市場は2018年7月基準で2023年までに年平均成長率は48%以上と予想され、この成長基盤には知能型ビジネスプロセスに対する必要性の増大やIoT、Connected Deviceの増加による大容量データ生成と運営費用の減少に対する必要性などが作用したと分析されている。さらに、既存インフラおよびスマートシティプログラムの向上に向けた世界各政府や企業、自治体の努力を踏まえ、全般的なAI Service Marketの成長が促進されていて、これは持続すると予想される。

このように、AI技術は持続的な成長が期待できる高付加価値産業であり、実際に収益創出が起きる市場であることを認識しなければならない。しかし、外形的な成長やその可能性と比べ実際にAI技術は市場と関わる問題やその解決策はまだ始まったばかりのレベルであることが現実である。

これにAIPEは、AI Predictionを中心にAI Modelを構築し、このDataがテストを経て商用化されることを望むAI研究員とAI Model Dataを仮想通貨投資への指標として活用したいと思う投資家、そして、蓄積されたAI Developer poolとAI dataを必要とする企業を相互連結するブロックチェーン基盤のプラットフォームを開発しており、研究員、投資家、企業が感じていた渇を癒やすことを目指している。

このプラットフォーム内で生産されて共有する全ての情報はブロックチェーン技術を通じて安全に管理され、AI研究員全員とAI Modelを使用する投資家は、自分が創り出したコンテンツおよび個人情報に対する所有権や管理権限を行使することができ、これを企業参加者に共有し貢献する場合、それに対する報酬をもらえる。

また、参加者全員と企業は、AI Prediction Platformが提供するAPIを利用してこのプラットフォーム内で多様なOn Demandサービスを具現することができる。我々AIPEチームは、AI Prediction Platformを通してAI研究員が保有しているPrediction Modelと実際に使用者のデータ所有権および管理権限を必要なところに再分配し、それに対して明確な報酬を与えることで必要な価値が好循環すると共にこれを基にAI産業の革新に貢献することを目指している。

SERVICES

3PIKS

AIとブロックチェーン技術を融合した独創的なリワードプラットフォーム

我々は、‘人工知能(AI)’と‘人間の判断 (Human Factor)’が結合された仮想通貨価格予測サービスを提供するためにAIと仮想通貨市場を組み合わせた3PIKSを開発した。

仮想通貨市場への参加者は、3PIKSサービス内のAIモデルの価格予測だけではなく、3PIKSユーザーらの予測が集まって形成された結果を一種の集団知性として参考にすることができる。ユーザーは自社独自で開発したAIモデルと共に仮想通貨の価格を予測し、それに対する報酬としてAI Tokenを手に入れる。AI Tokenは、今後AIPE Coinに交換ができ、戦略的にパートナーシップを結んでいるパートナー社のトークンおよびコインとも交換できる。このように使用先に対する多様性を持つ方法で生態系を構成する。

AlBitBip

AI基盤仮想通貨ボラティリティ予測信号サービス

売買の際に役立つようAIモデルが意味のある上昇/下落の兆しを捕え、これを信号形式で通知サービス化する。ユーザーのアクセシビリティを高めるためにアプリケーション形式でプロトタイプを開発し、2019年第2四半期に 론치를 予定している。 初期には、独自で開発した数十種のモデルを優先的にサービスし、今後、AI Prediction Platformで開発された様々な研究員のモデルを選別して追加および拡張していく予定である。

AlBitBipの価値は単に売買に対する情報を知らせてくれることに留まらない。不特定多数が該当信号を参考に売買するのなら、これは一つの大きな集団として分類することができる。同一時点に大量の資本が投入され価格の流れを作ることになると、投資に対するリスクは大幅減らせることになり、ユーザーはこれを売買に対する参考資料として利用することができる。さらに、売買に対するリスクもまた減らせると思われる。アプリケーションの特性上、便利性且つアクセスの容易さからユーザーへの露出度が高い。これは、アプリケーション内の各種の広告掲載およびReferralシステム使用先としても拡張できる。

AI Auto-Trading

AI Prediction Signalを基にしたAuto-Trading Bot

AlBitBipを通じてSignalをもらうとしても誰もが売買で収益を得られることではない。24時間、大規模の取引が

行われる仮想通貨市場でユーザーがSignalをみてリアルタイムで買い・売りを行うことは簡単ではない。これを解決するために我々は、各取引所のAPIを用いたAI Auto-Trading Botサービスを予定している。該当プロジェクトの成功のために長い間AI Prediction Signalを通じた売買を試みてきた。沢山の試行錯誤があったが、AIの学習が重なりつつ的中率や収益率の漸進的な上昇が見られた。

正確なタイミングでの買い・売りを通じて収益を得られるサービスを提供し、ユーザーが収益を得ることに焦点を合わせている。該当サービスを利用するためにはAIPEを一定以上所有しなければならない、Auto-Tradingの収益の一部を研究員と共有することで生態系は維持される。

また、Auto Tradingは単に収益のみ作り出すのではなく、Exchangeとも緊密な協力関係に置かれる。該当 Auto Tradingを進行するためには、数多い呼び値登録と締結の過程を繰り返さなければならない。これを通じてExchangeは多い取引量と通貨流動性が確保でき、Marketを形成するのに重要な機能を果たす。我々は、B2Bビジネスを通してユーザーとExchange、そして、Prediction Platform発展に相互補完的な生態系を形成することができる。

AI Prediction Platform

AI研究-開発環境の改善や検証済みのData確保が可能なAI Prediction Platform

現在、AI研究において最もの参入障壁は、多量のDataを精製することとComputing Powerの確保であるだろう。個人がこのような環境をセッティングすることは不可能に近く、AI model dataを必要とする企業の状況もまた変わらない程、劣悪な環境である。

AIPEでは、このようなAI研究開発の環境を改善するためにAI Prediction Platformを導入しようとする。PlatformにてAI研究員はOpen Source Library環境で容易にアクセス-利用ができ、企業はTrafficやModel Dataを確保することができる。こういう環境下で大勢のAI研究員がPlatformにて提供するDataツールを使用し、多様なAI Modelを作り出すことができるなら、クラウド提供企業の市場参入障壁も低くなる。これを通して体系的なAIモデルの管理やData共有が円滑になり、サーバー使用コストの削減、様々なTrading Bot /アルゴリズムの増加、ユーザーのアクセスもまた増加することで新たな資産運用トレンドの始まりになると思われる。

このように、AIPEが提供するPlatform InfraはAI研究員と投資家、そして、企業の便宜のみに限られず、人工知能産業のvalue chain全般の革新を呼び起こすというところで大きな意味がある。

Exchange Solution

多くの企業が仮想通貨取引所開発やサービスに試みるが、時間的かつ物理的な費用とともに技術的に専門性が欠けていたりマーケティングが不在したりして難航している。

AIPEは、このような問題を解決するために独自開発した仮想通貨取引所のソリューションを提供する。既存の中央化取引所に対するソリューションを提供することはもちろん、マージン取引やレバレッジ取引に対応する仮想通貨マージン取引所を開発している。当社が開発しているマージン取引所は‘BitMEX’のようなマージン先物取引を対応し、ひいてはマージンオプション取引まで対応する予定である。

仮想通貨取引所に関するソリューション会社は沢山あるが、みんな中央化取引所向けに限られている。AIPEは、マージン取引が可能な取引所に留まらず、デリバティブの先物取引、オプション取引提供にマージン取引を加えたマージン先物取引、マージンオプション取引まで対応する仮想通貨投資ソリューションを提供する。

AI Prediction Ecosystem

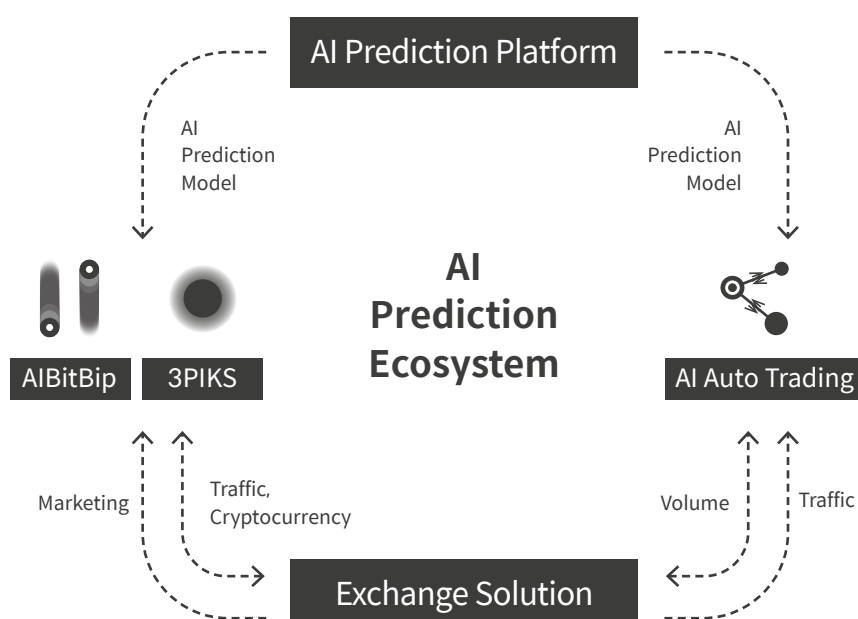
AIPEのAIサービスが共存するエコシステムビジョン

AIPEが目指すビジョンは、各サービスの固有の価値が一つの有機的仮想通貨生態系を構成することである。

リワードプラットフォームの3PIKSと仮想通貨価格変動を知られてくれるサービスのAIBitBip、両サービスを利用してユーザーへコインおよびトークンをAirdropすることができ、取引所や特定コインのマーケティングチャンネルとしての活用が可能になる。

また、3PIKSでは、AI Token(仮)を報酬としてもらい、協約社のTokenおよびCoinにSwapができるように進めている。Swapされたコインは自社のマーケティングサービスを対応する取引所にて出金可能になり、これを通して取引所のTrafficや流動性を確保することができる。

このように、AIPEのEcosystemは単に優れたAI Modelの確保や取引所開発に必要なソリューションだけを提供することではなく、各サービスが相互有機的な関係と価値を持ち、仮想通貨の価格予測、通貨流動性、広報、トラフィック、そして、市場の安定性を循環させる構造を持つようになる。



AI技術

概要


AI開発が最も核心的なProjectであるため、我々はAI Research Labを運営している。初めにPrediction Modelを開発する時には、Deep Learning方式のモデルを用いたが、次第に拡大されMachine LearningやDeep Learning両方を総合したモデルを開発している。

既存のDeep Learning方式を大略に表現すると、RNNとCNNの方法論を用いたモデリングシステムの構築である。該当の時系列データをモデリングに投入するための前処理が大変重要になる。RNNに投入されるデータの処理はNoiseを効果的に除去することに重点をおいている。また、CNNに投入されるデータ前処理は、パターンを効率的に表すことに重点を置く。こういったRNNとCNNの方式を独立に利用することもあるが、相互補完的にモデリングを試みた。Machine Learning方法論では、決定木(Decision Tree)の不安定性を補うために一般的に使われる方法の一つであるGradient Boostingを用いて予測モデルを構成している。

Learning Machine モデルの訓練のために2017年7月頃から今まで約100,000個の仮想通貨時系列データを使用した。時系列データとしては、高値、安値、市価、終値、取引量など5つのFeatureを利用した。最近、研究が加速するとともに上記5つの基本Feature以外にも技術的指標などを利用したFeatureエンジニアリングを通して作られた多様なfeatureを使用している。

Machine Learningモデルは投入データが多ければ多いほど高い正確度を見せる傾向がある。しかし、モデルごとに特徴が異なり、時系列データの特性上、変動的な要素があるため無条件に多いデータを投入して訓練させることが能ではないと思われる。実際、各々のモデルは選別したデータで訓練させたときに高い性能を見せた。例えば、特定種類のCNNモデルは最近の1万8千個の時系列データで訓練させたときに分類の正確度が最も高かったが、あるLSTM類のモデルは全体データで訓練させたときに最も良い性能を見せた。

我々が使っているモデルの構造を簡単にいうと次の通りである。



[図] Staked wavelet LSTMモデル構造

RNN方法論を取る場合、複数のLSTMもしくは、GRU層を積んだStacked LSTM/GRUが良い性能を示した。また、Wavelet変換を経たRNN類のモデルも満足できるような結果を見せた。CNNモデルは、畳み込み層の個数と活性

関数の組み合わせが性能を高めるのに重要な要素になることがわかった。層が多ければ多いほど過剰適合の問題があり、ドロップアウトと配置正規化を適切に使用した。LSTMセルと畳み込み層を並列に積んだ混合モデルも良い性能を示した。Gradient Boostingの場合、XGBoost、LightGBM、Catboostなどの方法論を借用した。Boosting系列のMachine Learningモデルの場合、性能はfeature選択やデータの規模に依存される。

主要技術紹介

概要

当社は、約10人規模のA.I.研究チームを構成しこの研究を進めており、研究方法は次の通りである。まず、英語、中国語、韓国語圏の主要研究論文を研究し、その中で殆どを実際に具現してみる。これを通して2018年8月から2018年12月まで約500の論文を参考にした上、実際に具現したモデルの中で当社基準に適合した成果が出るモデルを再び持続的に学習させることで利用方法を改善する。有意味な参考研究論文に対しては、cosmicbc.comのR&D Blogにより確認することができる。当社は、研究成果を継続して開示し、これからも引き続き開示していく予定である。現在、2018年12月時点で100余りの論文の内容を実際のサービスに具現した。

当社は、このように具現したモデルをAmazon web service(AWS)、Naver Cloud Platform(NCP)、Alibaba CloudのA.I. Cloud computing serverを利用して具現し、研究を進めている。まず、殆どのモデルが具現された状態で過去のデータを使用して学習させ、2-3週間のLive data学習を通じて実際にどの程度のパーセンテージの正確度を持つかを確認する。これを基準にして特定数値以上の確率を見せるモデルを中心に多様な変形処理方式を具現し、1ヶ月以上学習させる。

RNN

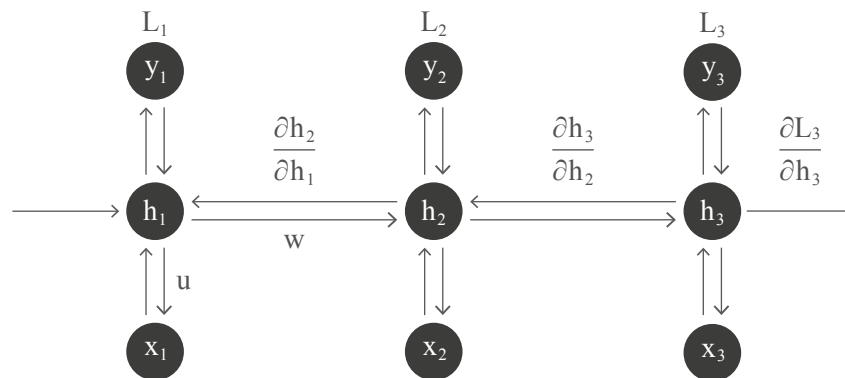
RNN (Recurrent Neural Network) 又は、循環ニューラルネットワークモデルの特徴は、完全連結型ニューラルネットワークである。後述のCNN (Convolutional Neural Network; 畳み込み層ニューラルネットワーク 又は、ConvNet)にはないメモリを持つ。これは、連続列データの予測分類問題を解くことに適合している。連続列データとは、各々の要素に順序のある集まりで与えられる時系列データとして音声、動画、テキストなどを例に挙げられる。これは、次のような形で表現できる。

$$x^1, x^2, x^3, \dots, x^T$$

ここで連続時系列の長さ $t=1,2,3,\dots,T$ は、一般的に可変的である。実際、連続列データを扱う推定問題の例として、ある文章の t 番目の単語まで与えられた際、 $t+1$ 番目の単語を予測することができる。各単語は、前の単語の連続列に強く影響を受けたりする。RNNは、単語間の依存関係、つまり、文脈を学習して高い正確度の予測を行っていると評価される。仮想通貨のような時系列データの場合、前のデータが現在のデータに影響を与える場

合が大変多い。RNNは、上記のメモリ構造のおかげで情報を一時的に記憶し、それによって反応が異なるようにすることができる。連続的時系列データの‘文脈’を掴み、分類問題の処理もできる。つまり、RNNを仮想通貨の動き予測分類問題を解くのに適用することができる。

RNNを学習させる際には、完全連結型ニューラルネットワークと共に最急降下法 (Gradient Descent)を使用する。各層の加重値に対する誤差の微分を計算しなければならないが、ここには2つの方法を適用することができる。一つは、Realtime Recurrent Learning (RTRL)、もう一つは、Back Propagation Through Time (BPTT)である。前者はメモリ使用の効率性が高い半面、後者は計算速度が早い。



図] BTPP概要

※出所：Hands-On Reinforcement Learning with Python by Sudharsan Ravichandiran

BPTTは、RNNを時間方向に展開して完全連結型ニューラルネットワークと同じ構造に変更した後、バックプロパゲーション計算を実行する。上図のように時刻毎のRNNを列に並べて中間層の帰還路を連続する時刻の中間層のユニットへの結合で表現する。このように展開したニューラルネットワークは、既存の完全連結型ニューラルネットワークになり、それによってバックプロパゲーションを通して傾きを計算することができる。既存のバックプロパゲーションのように以前の層に電波されるデルタを定義することができるのだ。

$$\delta_2^{(3)} = \frac{\partial L_3}{\partial z_3} = \frac{\partial L_2}{\partial h_2} \frac{\partial h_2}{\partial s_2} \frac{\partial s_2}{\partial z_2}$$

$$\text{ここで } z_2 = Ux_2 + Ws_1$$

以前の時間ステップにも同じ方法を適用すると次のとおりである。

$$\delta_1^{(3)} = \frac{\partial L_3}{\partial z_1} = \frac{\partial L_3}{\partial h_2} \frac{\partial h_2}{\partial s_1} \frac{\partial s_1}{\partial z_1} = \delta_2^{(3)} \frac{\partial h_2}{\partial s_1} \frac{\partial s_1}{\partial z_1}$$


前述したようにRNNは、連続列データの文脈を捕え推定可能になるが、この際、捕えられる文脈の長さに敏感に影響を受ける。

理論的には、時間 t から以前の全タイムステップの情報を保持することができるが、長い時間に渡った依存性は学習できなくなる問題が発生する。実際、RNNの出力に反映させられるのは最大に過去10時間程度と把握された。

こういった限界により層数が多いニューラルネットワークには、逆伝播法で傾きを計算する際、層を遡ることで傾き値に発散か消失しやすい性質が付与される。即ち、RNNの層数が少ないとしても逆伝播計算の際には、多い層数を扱うことと同値になり、それによって傾き値も発散か消失しやすくなる。RNNで長い連続列を扱いにくいのはこの理由からである。短期的記憶は実現できるが、長期的記憶を実現するのは難しいということと同じである。

LSTMとGRU

1990年代初め、ホフライター(Hochreiter)、シュミットフーバー(Schmidhuber)、ベンジオ(Bengio)が前述の問題に対する理論的な考察を通じてこれを解決するための方法をいくつか紹介した。その中で最も成功的な方法は、長・短期記憶(Long Short Term Memory ; LSTM)で知られている。LSTMは、前述した基本的なRNNと比べ中間層の各ユニットがメモリユニットと呼ばれる要素で構成されている構造であって、それ以外の構造は既存RNNと完全一致する。



[図] RNN、LSTMの構造比較


※ 出所 : <https://ratsgo.github.io/natural%20language%20processing/2017/03/09/rnnlstm/>

コンベヤベルトの役割を果たすセル状態(Cell-state)を想像すると理解しやすくなる。情報を複数のタイムステップに渡って移動させる方法が追加されている。時系列のある時点から抽出された情報がコンベヤベルトに上がって、必要な時点のタイムステップに移動して降りてくる。後のために情報を保存することで処理過程で古いシグナルが徐々に消失されることを防いでくれるのがLSTMの役割である。

数式で解いてみると、LSTMセルの数式は下記の通りである。ここで \odot は、要素別乗法を意味するHadamard product 演算子である。

$$\begin{aligned}f_t &= \sigma(W_{xh_f}x_t + W_{hh_f}h_{t-1} + b_{h_f}) \\i_t &= \sigma(W_{xh_i}x_t + W_{hh_i}h_{t-1} + b_{h_i}) \\o_t &= \sigma(W_{xh_o}x_t + W_{hh_o}h_{t-1} + b_{h_o}) \\g_t &= \tanh(W_{xh_g}x_t + W_{hh_g}h_{t-1} + b_{h_g}) \\c_t &= f_t \odot c_{t-1} + i_t \odot g_t \\h_t &= o_t \odot \tanh(c_t)\end{aligned}$$

Forget gate f_t は、過去の情報を忘れさせてくれるゲートである。 x_t と h_{t-1} の入力を受けてシグモイドを適用させた値がforget gateから送り出される値である。その値が0であれば、前の状態の情報は忘れ、1であれば、それを完璧に記憶する。Input gate $i_t \odot g_t$ は、現在の情報を覚えるためのゲートである。 x_t と h_{t-1} の入力を受けシグモイドを適用し、また同じ入力でハイパボリックタンジェント(tanh)を適用した後、Hadamard product 演算をした値がInput gateから算出された値である。要するに、LSTMは、RNNが持つ長期間メモリ問題を解決し、様々な分野で成功的に活用されている。LSTMの成功後、LSTMの変種についての研究が活発になり学界で発表されている。その中で、注目したいのはジョ・ギョンヒョンが2014年に発表したGated Recurrent Unit(GRU)である。



[図] GRU概要

※出所： <http://sqlml.azurewebsites.net/2017/08/12/recurrent-neural-network/>

上図でわかるようにGRUの構造はLSTMの構造と比べ簡単である。詳しくみるとLSRMと同じくgateを利用して情報の量を調節するのは同だが、gateの制御方式において若干の差がある。

数式で解いてみると次のとおりである。

$$\begin{aligned}z_t &= \sigma(x_t U^z + h_{t-1} W^z) \\r_t &= \sigma(x_t U^r + h_{t-1} W^r) \\\tilde{h}_t &= \tanh(x_t U^h + (r_t * h_{t-1}) W^h) \\h_t &= (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t\end{aligned}$$

Reset gate r_t は、0から1の間の値を持ち、値が0に近いと過去の情報を全て忘れることになり、1であると過去の情報は全て覚える。最後列の数式は、次の状態でアップデートをコントロールする。 h_{t-1} は、過去の情報、 \tilde{h}_t は、現在の情報で、これをどのように組み合わせるかを決めるのはupdate gateの z_t である。

CNN

CNNとは、主にイメージ認識に応用されるニューラルネットワークモデリング手法である。コンピュータービジョンの難題と思われたこと(物体カテゴリ認識等)を驚くほどの性能で解決している。既存の完全連結型ニューラルネットワークの問題点は、小さいサイズの筆記体を認識するのに必要な加重値とバイアスの数が爆発的に増加するということであった。例えば、16x16サイズの筆記体を認識するために単一隠匿層に100個のニューロンを持つ完全連結型ニューラルネットワークを構想するとしよう。このネットワークが必要とする加重値とバイアスの数は総28,326個になる。このニューラルネットワークに隠匿層をもう一層積む場合、学習パラメーターの数はもっと多くなる。また、筆記体イメージに垂直/水平移動、回転、変形が生じると新しい学習データを入れなければならない問題が発生する。

この問題を解決するためにできたCNNは、完全連結型ニューラルネットワークとは違って隣接した層と層の間に特定のユニットのみ結合する特殊な層を持つ。その特殊な層では、畳み込み(Convolution)とプーリング(Pooling)というイメージ処理と関連した演算が発生する。

CNNの開発には、動物の脳内にある視覚野(Visual cortex)に対する神経科学的知識からヒントを得た。詳しく表現すると、視覚野に対する神経細胞の受容野(Receptive field)の局所性や単純型細胞(Simple cell)および複雑型細胞(Complex cell)の存在からインスピレーションを受けたと思われる。あるニューロンは水平線イメージにのみ興奮し、あるニューロンは違う角度のイメージに反応する。また、あるニューロンは大きい受容野を持っていて低いレベルのパターンで組み合わせられたもっと複雑なパターンに反応することがわかった。これを利用してLeNet、AlexNet、VGG、GoogLeNetなどの代表的なCNNモデルが作られ、イメージ分類において人間以上の性能を見せている。

CNNの基本構造について次のように要約できる。入力イメージを受ける最初の畳み込み層のニューロンは入力イメージの全ピクセルに繋がるのではなく、畳み込み層ニューロンの受容野内のピクセル

ルのみに繋がる。しかし、畳み込み層は線形演算を実行する。従って、もっと複雑な非線形関係を学習させるために代表的にReLU(Rectified Linear Unit)のような非線形活性化関数を畳み込み層に繋ぐ。その後、プーリング層は、演算量とメモリ使用量およびパラメーター数を減らすために入力イメージの副標本(subsample)を作ってくれる役割を果たす。データーの性格によって畳み込み層+活性化関数+プーリング層の組み合わせで多様に層を積むことができる。通常は、CNNは出力前に一層以上の完全連結層を付けるが、これは高次元の特性マップの最後層をイメージ分類にマッピングできるようにする。

上述のように、CNNにおいてもっと大事な構成要素は畳み込み層である。WXWサイズの黒白イメージがあり、各ピクセル(Pixel)のインデックスを(i,j)としよう。そして、HXHサイズのフィルター(Filter)があってフィルターのピクセルのインデックスは(p,q)で、 $p,q=0,\dots,H-1$ とする。ここで $H<W$ である。厳密にいて畳み込み層とは、次のように定義される。

$$u_{ij} = \sum_{p=0}^{H-1} \sum_{q=0}^{H-1} x_{i-p, j-q} h_{pq}$$

畳み込み層の次に来るプーリング層の計算内容は、以下のように簡単に説明できる。サイズWXWXKの入力イメージのピクセル(i,j)を中心とするHXHサイズの正方形領域に含まれるピクセルの集合を P_{ij} としよう。適切にパディングを適用すると、イメージのエッジも含んだ P_{ij} を構築することができる。この P_{ij} 内のピクセルに対してチャンネルk毎に独立的に H^2 個あるピクセル値を利用し、一つのピクセル値の u_{ijk} を求める。代表的にこのピクセル値を求める方法としてマックス(max)プーリング、平均プーリングがある。

マックスプーリングは、 H^2 個のピクセル値のうち、最大値を選ぶ方法であり、計算式は次の通りである。

$$u_{ijk} = \max_{(p,q) \in P_{ij}} z_{pqk}$$

平均プーリングは、 H^2 個のピクセル値の平均を求めてピクセル値とする。

$$u_{ijk} = \frac{1}{H^2} \sum_{(p,q) \in P_{ij}} z_{pqk}$$

最後に、マックスプーリングと平均プーリングを併せた L_p プーリングは次のとおりである。プーリング演算は、入力イメージの各チャンネル毎に並列に実行される。つまり、プーリング側の出力チャンネル数とイメージチャンネル数が同じであることになる。 L_p プーリングを数式で表すと

$$u_{ijk} = \left(\frac{1}{H^2} \sum_{(p,q) \in P_{ij}} z_{pqk}^p \right)^{\frac{1}{p}}$$

であり、 $P=1$ であれば平均プーリング、 $P=\infty$ であれば、マックスプーリングになることがわかる。

価格予測分類問題で時系列データーの動きをパターン化して分析することができる。CNNを用いて構成した強力な予測力を持つと判断される。

Gradient Boosting

Gradient Boostingは、上述した最急降下法(Gradient Descent)とブースティング(Boosting)の合成語である。ブースティングは相対的に単純な決定木(又は、学習器)を成長させて順次に(sequential)学習させ、この結果に基づきもう一つの決定木を成長させる手法である。最急降下法という名称でわかるようにGradient Boostingは、損失関数で微分可能な全ての関数を使用できる。

Gradient Boostingのアルゴリズムは、次のように表せる。

$$h_0(x) = \arg \min_{\gamma} \sum_{i=1}^n L(y_i, \gamma)$$

まず、学習器(h)を初期化し、各 $m=1,2,\dots,M$ に対して1、2、3、4を繰り返す。

$$r_{im} = - \left[\frac{\partial L(y_i, h(x_i))}{\partial h(x_i)} \right]_{h(x)=h_{m-1}(x)}, \\ i = 1, 2, \dots, m$$

1. 疑似残差(pseudo-residual)を計算する。

$$\{(x_i, r_{im}) \mid i = 1, 2, \dots, n\}$$

2. 疑似残差に対して基底学習器 $h_m(x)$ を適合する。

$$h_m(x) = h_{m-1}(x) + \gamma_m h_m(x)$$

4. 学習器を更新する。

$$\gamma_m = \arg \min_{\gamma} \sum_{i=1}^n L(y_i, h_{m-1}(x_i) + \gamma h_m(x_i))$$

3. 次のように乗数 γ_m を計算する。

$$h_M(x) = \sum_{i=1}^M \gamma_i h_i(x) + h_0(x)$$

最終モデルは、次の通りに選定する。

価格動きに対する分類問題の場合、指数損失関数を使うと $r_{im} = y_i \exp(-y_i h_{m-1}(x_i)) = y_i w_{im}$ になる。 w_{im} は正分類の場合は、 e^{-1} 、誤分類の場合は、 e^1 になる。つまり、誤分類されたデーターにもっと大きな加重値を付与し次のステップに進めることになるのだ。疑似残差は、残差の一種であるためブースティックの一般化は損失関数が定義されている場合、最大傾斜法によって損失関数を最小化する過程である。

Gradient Boosting 手法を用いた代表的なモデルには、XGBoost、LightGBM、Catboostがある。

まず、XGBoostは、並列処理で学習や予測が速く、多様なカスタム最適化オプションを提供する。また、Greedyアルゴリズムを通じた自動剪定により過剰適合を防ぐことができ、他のアルゴリズムとの連携性が良い。

次にLightGBMの最もの特徴は、XGBoostより学習時間が短いということだ。また、メモリ使用量も相対的に少ない。XGBoostより2年後に開発されたため、長所は継承して短所は補う方式で作られたという。LightGBMのリーフ中心の分割方式はツリーのバランスを取らず、最大損失値を持つリーフノードを持続的に分割しながらツリーの長さが長くなり、非対称的な規則ツリーが生じる。しかし、これは、バランスツリー分割方式と比べて予測誤差損失を最小化することができる。

最後に、Catboostはordering principleの概念を代入して既存のターゲット流出(target or data leakage)による予測シフト現象 (prediction shift)と範疇型変数に対する前処理問題を解決した。前者についてももう少し詳しく記述すると、leaf valueを計算する過程で ordered boosting 手法を活用した。既存のGradient Boosting は、新しいツリーを作る際、現在のモデルで使われたデータを再使用するため、過剰適合に脆弱な問題点があった。既存の方法とは違って逆順で leaf valueを先に求めてツリーの構造を選ぶ過程を採用した。


TOKEN ECONOMY

Coin Structure


総発行量	12億枚
単位価格	1AIPE = 約 0.01 USD
コイン名	AI Prediction & Ecosystem Solution
コインシンボル	AIPE
Standard	ERC-20
Decimal	18
Hard Cap	412,500,000 AIPE
Soft Cap	137,500,000 AIPE

Allocation

AIPE の発行は、Platform の開発および AI Prediction を基にした Ecosystem 造成のために利用される。ICOおよびIEOへの参加者には、全発行量の中、40%に該する流通量が支給される。Coin Saleを除いた残余物量の中、20%は初期Ecosystem形成に必要なAI Prediction Platformの構築およびMarketingに使われる。AIPE Reserveに該する12%の物量はPlatformの追加開発およびPlatformの拡張により増えるインフラ構築のために使われる。Reserve物量12%とTeam配分物量10%は順次に配分される。




Ecosystem



SERVICE	INFO
Blockchain Develop	ブロックチェーン研究を通じてAI Develop Platformを維持し、開発されたモデルに対する権利保障に積極的に活用する。 公信用を持つための手段としてAI Prediction DatabaseをBlockに保存する研究を支援。
AI Develop	AI研究員の教育や研究のための環境づくりおよび予測モデル開発に積極的支援。 Machine Learning基盤のBig Data分析アルゴリズムに対する持続的研究。
Solution Develop	総合ソリューションのためのProduct開発。 3PIKS、AIBitBip、AI Auto-Trading Bot、Exchange、Margin Exchange開発。
Marketing	現在、ブロックチェーン産業は激しい競争領域であることを考慮し、当社のプラットフォームの手早い定着のために各種のマーケティングチャンネルを積極的に活用しユーザーを確保、プラットフォーム定着に利用する。
Legal	サービス開発および運営上発生し得る各種の著作権や関連法律の処理。

ROADMAP



NOTICE & CAUTION

AIPEプロジェクトのホワイトペーパーは、プロジェクト全般的な内容やロードマップを具体的に説明するために作成されました。このホワイトペーパーは、投資などを推奨する目的で作成されたわけではありません。このホワイトペーパーを読んでいただく方々がこのホワイトペーパーを参考の上、発生し得る損害、損失、債務などの財務的被害が発生するとしてもAIPEはこれに対する賠償、補償、その他の責任を負担しないことにご注意ください。

このホワイトペーパーを読んでいただく方々が自分の意思決定などの行為においてこのホワイトペーパーを利用（このホワイトペーパーを参考 或いは、根拠にする場合も含むが、これに限定はしない）した場合に発生する全ての金銭的且つ債務的被害についてAIPEはいかなる賠償、補償、その他の責任を負いません。再度ご注意の程お願い申し上げます。

AIPEプロジェクトのホワイトペーパーは、‘作成完了時点基準 (as is)’ で作成し提供するもので、ホワイトペーパーに含まれたいかなる内容が将来時点まで変更しないことについては保障しません。

AIPEは、このホワイトペーパーと関連してホワイトペーパーを読んでいただく方々にいかなる事項についての表明および保障、これに対する法的責任を負いません。例えば、AIPEはホワイトペーパーは、適法な権利に基づいて作成されており、第三者の権利を侵害しないか、ホワイトペーパーが商業的に価値があるか、それとも有用か、このホワイトペーパーを読んでいただく方々が持っている特定の目的達成に適合しているか、ホワイトペーパー内容に誤謬はないかなどについて保障しません。責任免除の範囲は、言及した例に限られません。

このホワイトペーパーは、AIPEチームの同意なしに無断コピーや使用、又は、外部への流出を禁じます。

